

PREDICCIÓN DE MUERTE DE PACIENTES CON LEUCEMIA DEL INSTITUTO NACIONAL DE ESPECIALIDADES NEOPLÁSICAS UTILIZANDO TÉCNICAS DE CLASIFICACIÓN DE MACHINE LEARNING

Angulo Mogollón,
Leonardo Martín

Lima, Perú

langulomogollon@gmail.com

Vásquez Chávez, Jule
Franve

Lima, Perú

jvasquez@inen.sld.pe

Abstract—

Keywords--Machine Learning, Aprendizaje Supervisado, SVM, Predicción de Muerte, Neoplasia, Cáncer, Técnicas de Clasificación, Pacientes, Leucemia, Instituto Nacional de Especialidades Neoplásicas

I. INTRODUCCIÓN

La presente investigación se realizó con la data proporcionada por el especialista en donde se pretende demostrar que por medio de las técnicas de machine Learning se puede automatizar la clasificación de vida de los pacientes y obtener la mejor precisión posible de la clasificación. Para ello se utilizó las técnicas de Regresión Logística, Naive Bayes, SVM y Redes Neuronales. En los siguientes puntos se especifica la metodología y los experimentos que se realizaron para la presente investigación.

II. METODOLOGÍA

La metodología propuesta para el desarrollo de la presente investigación consta de tres etapas: Pre-Procesamiento, Procesamiento y Entrenamiento del Modelo.

En primer lugar, se realizó la etapa de Pre-Procesamiento, en donde, como primer paso se accede a la base de datos proporcionada por el especialista, para extraer las bases de datos indispensables para el desarrollo de la presente investigación, las cuales son: Base completa DLBCL 2021 24 de ENERO 130LAST, base nueva MM 13-18 TOTAL, HL ASH21 1382 Nov23, Linfoma folicular ASH Nuevas Variables Junio 30,

Linfoma Malt ASH21 Aug6 (versión 2 completa), LLC 2022 feb8 0left, Manto ASH 2021 July 24 up22, los cuales han sido adjuntados en un solo archivo nombrado Data Master Limpia formado aproximadamente de diez mil (10,000) registros para realizar la limpieza, preprocesamiento, análisis univariado, análisis bivariado, análisis gráfico, análisis de correlación y el entrenamiento con diversas técnicas de clasificación para poder predecir la muerte en los pacientes tratados.

En segundo lugar, se estableció la lectura de datos y la comprobación de valores nulos.

```
1: data.isnull().sum()
2:
3: n*
4: edad
5: subtipo de linfoma
6: sexo
7: lugar de proc
8: estadio
9: sitioprim
10: nodal vs extranodal
11: es cl
12: ecog
13: hemoglobina
14: conteo absoluto de neutrófilos (valor)
15: conteo absoluto de linfocitos (valor)
16: conteo absoluto de monocitos (valor)
17: dh1 valor
18: albúmina valor
19: h2 microglobulina valor
20: > 1 sitio extraganglionar (médula ósea, tracto gastrointestinal, hígado, pulmón, SNC, piel, testículos, anillo de Waldeyer, mama, etc)
21: compromiso de médula ósea
22: masa bulky (cm)
23: rt a masa bulky o sitio extranodal (modalidad combinada qt seguida de rt)
24: Vth
25: htiv-1
26: compromiso del SNC
27: tratamiento de primera línea
28: número de ciclos de tratamiento
29: respuesta al tratamiento de primera línea
30: recaída post trasplante
31: es
32: dtype: int64
```

Figura 1. Comprobación de Valores Nulos

Fuente: (Fuente Propia, 2024)

En tercer lugar, se el análisis gráfico de los datos de las diversas variables cuantitativas. En donde se observó con mayor precisión la distribución de la data según ciertas características:

La distribución de los pacientes de la base con compromiso Nodal es de 61.09% y de compromiso Extranodal es de 38.91%.




Figura 2. Distribución Nodal vs Extranodal
Fuente: (Fuente Propia, 2024)

La distribución de los pacientes de la base con vida es de 72.43% y muerto es de 27.57%.




Figura 3. Distribución de Pacientes con Vida o Muertos
Fuente: (Fuente Propia, 2024)

La distribución de masa Bulky 7cm de los pacientes de la base si es de 31.41%, no es de 61.04% y de data desconocida es de 7.56%.





Figura 4. Distribución de Masa Bulky 7cm
Fuente: (Fuente Propia, 2024)

La distribución de edades de la mayoría de los pacientes de la base se encuentra entre 60 y 70 años.



La distribución de edad de los pacientes representa una distribución normal.




Figura 5. Distribución de Edad de los Pacientes
Fuente: (Fuente Propia, 2024)




Figura 6. Distribución de la Edad vs Tratamientos
Fuente: (Fuente Propia, 2024)

III.EXPERIMENTOS

Se realizó los experimentos utilizando las técnicas de Regresión Logística, en la cual se tomó las variables cuantitativas:

age,hemoglobina,dhlvalor,albuminavalor,b2microglobulina valor,numerodeciclosdetratamiento y como variable predictiva el estado actual (ea) que determina el estado muerto o vivo. De los cuales se obtuvo los siguientes resultados:

Tabla 1. Resultados de Clasificación Vivo o Muerto con Técnicas de Machine Learning

Técnica	Balanceo	Accuracy	Curva ROC
Regresión Logística	Sin Balanceo	76%	63%
	Smote	63%	68%
	Undersampling	61%	64%
	Oversampling	64%	63%
Redes Neuronales	Sin Balanceo	70%	63%
Naive Bayes	Sin Balanceo	64%	64%
	Smote	53%	60%
	Undersampling	53%	60%
	Oversampling	60%	65%
Random Forest	Sin Balanceo	74%	65%
	Smote	65%	71%
	Undersampling	65%	70%
	Oversampling	73%	82%

Fuente: (Fuente Propia, 2024)

Después de realizado los experimentos con las técnicas especificadas en el cuadro anterior, se puede concluir que las técnicas que mejor han realizado la predicción de muerte en los pacientes pertenecientes a la base de datos ha sido la de Regresión Logística con una precisión de 76% y una curva ROC de 63% y la técnica de Random Forest con una precisión de 73% y una curva ROC de 82%.

REFERENCIAS

- [1]Aguilar, A. (2023). *Amazon factura 127,400 millones, pero el crecimiento de su nube ese rentaliza a pesar de la fiebre por las IA generativas*. Obtenido de: <https://www.businessinsider.es/crecimiento-nube-amazon-lento-pesar-ia-1237184>
- [2]Alibabacloud (2023). *Exploración de Aplicaciones y Análisis de Big Data en la Nube*. Obtenido de: <https://www.alibabacloud.com/>

- [3]Amazon (s.f.). *Big Data en AWS*. Obtenido de: <https://aws.amazon.com/es/big-data/use-cases/>
- [4]Amazon (s.f.). *¿Qué puedo hacer con big data en AWS?* Obtenido de: <https://aws.amazon.com/es/big-data/use-cases/>
- [5]Anteneh, A., Heidar, D., Mehdi, K., Nigussie, M. Morteza, Z. (2021). *Leveraging non- respondent data in customer satisfaction modeling*. Obtenido de: https://doi.org/10.1016/j.jbusres.2021.06.006__
- [6]Aguilar D., Alcocer J. (2022). *Aplicación de Machine Learning para Optimizar la Atención de los Clientes en la Empresa Automotriz A&S Palermo SAC*. Obtenido de: <https://hdl.handle.net/20.500.12727/10169>
- [7]Aydaley (s.f.). *Amazon y el Big Data. Una Historia de Éxito*. Obtenido de: https://ayudaleyprotecciondatos.es/big-data/amazon/#Mejora_de_la_experiencia_de_usuario
- [8]Hammond, M.(s.f.). *Satisfacción del Cliente: qué es, sus elementos y como medirla*. Obtenido de: <https://blog.hubspot.es/service/satisfaccion-del-cliente>
- [9]The Information Lab (s.f.). *Cómo utiliza Amazon el Big Data*. Obtenido de: <https://www.theinformationlab.es/como-utiliza-amazon-el-big-data/>